

TRABAJO PRÁCTICO INTEGRADOR GRUPAL

Análisis Estadístico — Maestría en Ciencia de Datos UNAJ 2026

Integrantes	Martinez, Celeste Sabrina · Saenz, William Darío
Profesores	Prof. Ramiro M. Irastorza · Prof. Marcelo A. Cappelletti
Dataset	Estación Meteorológica — Corrientes, Mercedes (2023–2024) · 554 registros diarios
Entrega	30 de junio de 2026 · Entrega por campus (ZIP con notebook e informe)
Notebook	→ Ver notebook en Google Colab
Repositorio	→ GitHub: Celeste Martinez — Trabajo Final UNAJ WC



PARTE I — Estadística Descriptiva

I-A · Resumen y tipos de datos

Variable	Tipo	Unidad	Rango	Descripción
Fecha	date	—	2023-01-01 → 2024-11-22	Fecha de medición diaria
Temperatura_Abrigo_150cm	float64	°C	~5 a ~36	Temperatura del aire a 150 cm de altura
Humedad_Media	int64	%	Variable	Humedad relativa media diaria
Presion_Media	float64	hPa	Estable	Presión atmosférica media
Radiacion_Global	float64	MJ/m²	Variable	Radiación solar global diaria → variable a predecir

I-B/C · Medidas y gráficos — Principales hallazgos

Variable	Media	Mediana	Desv.Est.	Mín	Máx	Comportamiento
Temperatura (°C)	~22	~22	~5.5	~5	~36	Distribución simétrica · Marcada estacionalidad
Humedad (%)	Alta	Alta	Alta	39	100	Mayor variabilidad relativa (CV más alto)
Presión (hPa)	~985	~985	Baja	~960	~1010	Variable más estable · Próxima a Normal
Radiación (MJ/m²)	~18	~19	~6.5	~2	~35	Asimetría negativa · Alta dispersión estacional

I-D · Conclusiones descriptivas

- 554 registros diarios sin valores faltantes · Período: enero 2023 – noviembre 2024
- Temperatura y Radiación muestran estacionalidad anual marcada (veranos cálidos, inviernos moderados)
- El gráfico de dispersión evidencia tendencia positiva entre Temperatura y Radiación → se modela en Parte II
- La Humedad tiene efecto inverso sobre la radiación: días húmedos → más nubosidad → menos radiación solar

PARTE II — Regresión Lineal y Test de Hipótesis

II-A · Regresión lineal simple — Radiación = f(Temperatura)

$$\hat{Y} = 9.6899 + 0.4042 \times \text{Temperatura_Abrigo_150cm}$$

Por cada 1°C de aumento en temperatura → la radiación global sube ~0.40 MJ/m² en promedio

Parámetro	Valor	Interpretación
Ecuación ajustada	$\hat{Y} = 9.69 + 0.40 \cdot X$	Por cada 1°C extra → radiación sube ~0.40 MJ/m² en promedio
β_0 (intercepto)	9.6899	Radiación estimada cuando temperatura = 0°C
β_1 (pendiente)	0.4042	Efecto positivo de la temperatura sobre la radiación
R^2	0.0858 (8.58%)	La temperatura sola explica el 8.58% de la variabilidad de la radiación
R^2 ajustado	0.0841	R^2 corregido por el número de parámetros del modelo
F-estadístico	51.79	El modelo en su conjunto es significativo ($p = 2.03 \times 10^{-12}$)
r de Pearson	0.2929	Correlación positiva moderada-baja entre temperatura y radiación
Durbin-Watson	1.050	< 1.5: posible autocorrelación positiva (esperable en datos meteorológicos)

II-B/C · Análisis de residuos y R^2

- **Residuos estandarizados:** la mayoría de los puntos se ubica dentro de ± 2 → modelo razonablemente válido
- **QQ-plot de residuos:** buen alineamiento sobre la diagonal, con leves desviaciones en las colas extremas
- **$R^2 = 0.0858$:** el modelo simple explica el 8.58% de la variabilidad de la radiación. Valor bajo pero esperado — la radiación depende de múltiples factores no incluidos en el modelo simple.

II-D · Test de hipótesis completo sobre la pendiente β_1

Elemento del test	Valor / Resultado	Explicación
H_0 (hipótesis nula)	$\beta_1 = 0$	No existe relación lineal entre temperatura y radiación
H_1 (hipótesis alternativa)	$\beta_1 \neq 0$	Existe relación lineal estadísticamente significativa
Tipo de test	Bilateral (dos colas)	Se testea si β_1 es distinto de 0 en cualquier dirección
Nivel de significancia α	0.05	Probabilidad máxima de error tipo I aceptada (5%)

Elemento del test	Valor / Resultado	Explicación
Estadístico T_0	7.1962	Qué tan lejos está β_1 de 0 medido en unidades t
Valor crítico $\pm t(\alpha/2, n-2)$	± 1.9643	Si $ T_0 $ supera este valor $\rightarrow$ se rechaza H_0
p-valor	2.03×10^{-12}	Probabilidad de observar T_0 si H_0 fuera verdadera. Muy inferior a 0.05
DECISIÓN	✓ Se RECHAZA H_0	$ T_0 = 7.20 >> t_{\text{crit}} = 1.96 \rightarrow$ p-valor $<< \alpha = 0.05$

II-E · Supuestos de las variables aleatorias

Supuesto	Herramienta	Resultado	Conclusión
1. Normalidad	Shapiro-Wilk + QQ-plot	W=0.9915 p=0.0029	⚠ Se rechaza normalidad estricta. Con n=554 el test es muy sensible. QQ-plot muestra buen ajuste visual.
2. Homocedasticidad	Residuos vs Fitted + LOESS	Leve curvatura en LOESS	⚠ Sin patrón de embudo evidente. Supuesto parcialmente satisfecho.
3. Independencia	Durbin-Watson	DW = 1.050	⚠ DW < 1.5: posible autocorrelación. Esperable en datos de series temporales meteorológicas.
4. Linealidad	Gráfico de dispersión	Tendencia positiva	✓ El diagrama muestra relación lineal positiva entre temperatura y radiación.
Nota general	Las limitaciones en normalidad e independencia son esperables en series temporales. Las conclusiones del test se mantienen válidas por el Teorema Central del Límite con n=554.		

II-F · Regresión lineal múltiple — comparación con modelo simple

Métrica	Modelo Simple	Modelo Múltiple	Interpretación
Variables predictoras	Temperatura	Temp + Humedad + Presión	El modelo múltiple incorpora 2 variables adicionales
R²	0.0858	0.4579	+37.21 puntos porcentuales de mejora
R² ajustado	0.0841	0.4550	La mejora es real (no solo por agregar parámetros)
AIC	3876.94	3591.39	Menor AIC = mejor modelo (penaliza complejidad)
β Humedad	—	-0.3971	A mayor humedad → menor radiación (días nublados)
β Presión	—	+0.3317	A mayor presión → mayor radiación (días despejados)



PARTE III — Estadística No Paramétrica

III-A · Test de Spearman — equivalente no paramétrico al test sobre β_1

El test de Spearman trabaja sobre los **rangos** de los datos en lugar de los valores originales. No asume distribución Normal — es la alternativa robusta cuando los supuestos paramétricos no se cumplen plenamente.

Elemento	Pearson	Spearman	Diferencia clave
Coeficiente	$r = 0.2929$	$\rho = 0.3197$	Spearman levemente mayor por ser más robusto a outliers
p-valor	2.03×10^{-12}	1.25×10^{-14}	Ambos son extremadamente significativos ($p \ll 0.05$)
Trabaja sobre	Valores originales	Rangos de los datos	Spearman no asume normalidad ni distribución específica
Asume normalidad	Sí	No	Ventaja de Spearman cuando los supuestos no se cumplen plenamente
T_0 estadístico	7.1962	7.9275	Ambos superan el valor crítico ± 1.9643
DECISIÓN	Rechaza H_0	Rechaza H_0	✓ Ambos métodos concluyen lo mismo → resultados robustos

III-B · Conclusión general

- Existe una **relación lineal positiva y estadísticamente significativa** entre la temperatura del aire y la radiación solar global ($p \ll 0.05$ en ambos métodos)
- El **modelo simple** captura solo el 8.58% de la variabilidad — esperable dado que la radiación depende de nubosidad, humedad, estación del año y otros factores
- El **modelo múltiple** (Temperatura + Humedad + Presión) mejora el R^2 al 45.79% — la Humedad es el predictor adicional más relevante (efecto negativo)
- La concordancia entre Pearson y Spearman confirma la **robustez de los resultados** independientemente del cumplimiento estricto de normalidad



Tabla de Referencia — Conceptos, Métricas y Código Python

Guía de consulta rápida con todos los conceptos estadísticos del curso: cómo se calculan y para qué sirven.

Concepto	Categoría	Código Python	Para qué sirve
Media ($\bar{x}$)	Posición	<code>df[col].mean()</code>	Valor promedio. Sensible a outliers.
Mediana	Posición	<code>df[col].median()</code>	Valor central. Robusta a outliers.
Q1 / Q2 / Q3	Posición	<code>df[col].quantile(0.25/0.50/0.75)</code>	Dividen los datos en cuartos.
RIC	Dispersión	$Q3 - Q1$	Rango del 50% central. Robusto a outliers.
Desv. Estándar	Dispersión	<code>df[col].std()</code>	Dispersión en las mismas unidades que la variable.
Coef. Variación	Dispersión	$(std/mean)*100$	Dispersión relativa en %. Compara variables distintas.
Curtosis	Forma	<code>df[col].kurt()</code>	Mide si la curva es más puntiaguda (>0) o plana (<0) que la Normal.
Asimetría	Forma	<code>df[col].skew()</code>	Cola derecha (>0) o izquierda (<0).
β_0 / β_1	Regresión	<code>modelo.params['const'] / ['Temp...']</code>	Intercepto y pendiente de la recta ajustada.
R^2	Regresión	<code>modelo.rsquared</code>	% de variabilidad de Y explicado por el modelo.
Estadístico T_0	Test Hip.	$beta1/sqrt(sigma2/Sxx)$	Distancia de β_1 al valor nulo en unidades t.
p-valor	Test Hip.	$2*(1-stats.t.cdf(T_0 ,n-2))$	P(ver T_0 si H_0 fuera cierta). Si $< \alpha \rightarrow$ rechazar H_0 .
r de Pearson	Correlación	<code>stats.pearsonr(xi,yi)</code>	Correlación lineal entre -1 y 1 . Asume normalidad.
ρ de Spearman	No Param.	<code>stats.spearmanr(xi,yi)</code>	Correlación sobre rangos. No asume normalidad.
Shapiro-Wilk W	Supuestos	<code>stats.shapiro(residuos)</code>	Test de normalidad. H_0 : los residuos son normales.
Durbin-Watson	Supuestos	En <code>modelo.summary()</code>	~ 2 : sin autocorrelación. < 1.5 ó > 2.5 : hay autocorr.
AIC	Comparación	<code>modelo.aic</code>	Penaliza complejidad. Menor = mejor modelo.



Insights y Conclusiones Prácticas

	Hallazgo	Valor clave	Implicancia práctica
	Temperatura predice Radiación	$R=0.29$ / $p<0.05$	Estimar radiación solar sin piranómetros costosos es viable con modelos simples de temperatura.
	Modelo simple tiene limitaciones	$R^2=8.58\%$	La temperatura sola no alcanza: nubosidad, humedad y estación del año también determinan la radiación.
	Modelo múltiple mejora mucho	$R^2=45.79\%$	Agregar Humedad y Presión triplica el poder explicativo. La Humedad tiene efecto inverso (días húmedos = menos sol).
	Pearson $\approx$ Spearman	$r=0.29$ $\rho=0.32$	La relación es lineal y no está distorsionada por valores atípicos. Resultados robustos.
	Estacionalidad domina	Veranos vs inviernos	Agregar el mes o la estación del año podría mejorar considerablemente los modelos.
	Potencial para ML	AIC mejora con + vars	Con Random Forest o redes neuronales y más variables, R^2 podría superar el 80%.